

Lista de ejercicios 3 - Análisis de regresión

Ciclo nivelación 2025-2

Mg. Sc. J. Eduardo Gamboa U.

Una empresa de análisis inmobiliario desea modelar el precio de venta de departamentos en una ciudad usando información estructural y comercial. Se construyó una base de datos de 100 propiedades vendidas recientemente.

Variable respuesta: Precio de venta (miles de USD)

Variables explicativas:

- x1: Área construida, en metros cuadrados
- x2: Índice de calidad constructiva (z-score), es un puntaje técnico de materiales y acabados.
- x3: Intensidad de publicidad digital (z-score), es una medida de exposición en portales y anuncios.
- x4: Tiene cochera (0: No, 1: Sí)
- x5: Zona de la ciudad (A = Zona periférica, B = Zona intermedia, C = Zona comercial, D = Zona premium)

Objetivos:

- Identificar leverages, residuales y valores influenciales
- Seleccionar variables
- Reportar el modelo resultante e interpretar sus coeficientes estimados.
- Presentar un primer alcance sobre el uso de testing set.

1. División del conjunto de datos en entrenamiento y prueba

```
library(readxl)
datos = read_xlsx('Lista3_datos.xlsx')
```

Divide los datos en 2 particiones: entrenamiento (75%) y prueba (25%), usando la semilla 12369874. Como resultado, obtenemos 375 observaciones en el (sub)conjunto de entrenamiento y 125 en el de prueba.

```
library(rsample)
set.seed(12369874)
split_obj = initial_split(datos, prop = 0.75)
train     = training(split_obj)
test      = testing(split_obj)
train |> nrow()
```

```
[1] 375
```

```
test |> nrow()
```

```
[1] 125
```

2. Creación del modelo inicial de regresión lineal

El modelo se construye con los datos de entrenamiento.

```
modelo = lm(y ~ x1 + x2 + x3 + x4 + x5, data = train)
modelo |> summary()
```

```
Call:
lm(formula = y ~ x1 + x2 + x3 + x4 + x5, data = train)

Residuals:
    Min      1Q  Median      3Q     Max 
-11.7807 -1.0193 -0.1207  0.8529 13.9607 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 5.55013   0.42123 13.176 < 2e-16 ***
x1          1.35969   0.04177 32.553 < 2e-16 ***
x2         -0.55100   0.06354 -8.672 < 2e-16 ***
x3          0.02829   0.10227  0.277 0.782246  
x41         0.98436   0.20580  4.783 2.51e-06 ***
x5B         0.77653   0.27400  2.834 0.004851 ** 
x5C        -1.02727   0.26210 -3.919 0.000106 *** 
x5D         1.18452   0.32541  3.640 0.000312 *** 
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.976 on 367 degrees of freedom
Multiple R-squared:  0.9966,    Adjusted R-squared:  0.9965 
F-statistic: 1.532e+04 on 7 and 367 DF,  p-value: < 2.2e-16
```


3. Detección de leverages

Se crea un vector con las observaciones que son leverage en el modelo, usando el criterio $h_{ii} > \frac{2k}{n}$

```
modelo |> model.matrix() -> X
X %*% solve(t(X) %*% X) %*% t(X) -> H
train |> nrow() -> n
modelo |> coef() |> length() -> k
as.vector(which(diag(H) > 2*k/n)) -> leverages
```

Obtenemos una gráfica donde se aprecian los residuales vs leverage, donde se aprecia que las observaciones 357, 84 y 374 son algunas de las que presentan leverage alto.

```
library(olsrr)
modelo |> plot(which=5)
```



Se identificaron 7 leverage, y efectivamente las observaciones 374, 357 y 84 presentan leverage alto.

```
leverages
```

```
[1] 72 84 319 327 357 362 374
```


4. Detección de valores atípicos

Calcula los residuales estudentizados y verifica aquellos cuyo valor absoluto es mayor a 2. De ser así, esa observación sería outlier.

```
library(MASS)  
as.vector(which((modelo |> studres() |> abs()) > 2)) -> outliers
```

La gráfica nos permite ver que las observaciones 80, 84, 91, 163 y 357 son valores atípicos, porque están fuera de los límites (margen rojo)

```
modelo |> ols_plot_resid_stud()
```




Luego, esta gráfica permite ver las observaciones con alto leverage y también las atípicas.

Por ejemplo:

- 289: es un valor atípico pero no leverage
- 357: es outlier y leverage
- 319: es leverage pero no atípico

```
modelo |> ols_plot_resid_lev()
```

Outlier and Leverage Diagnostics for y



Se identificaron 9 valores atípicos:

outliers

```
[1] 72 80 84 91 163 289 357 362 374
```


5. Detección de DFFITS

Evaluamos los DFFITS del modelo, es decir aquellas observaciones que al ser retiradas ocasionan un gran cambio en los \hat{y}

```
modelo |> coef() |> length() -> k
train |> nrow() -> n
(abs(modelo |> dffits())) -> dffits
as.vector(which(dffits >= 2*sqrt(k/n))) -> inf_dffits
```

Gráficamente, apreciamos las observaciones con mayor DFFITS, siendo la 357 y 84 las que más influyen.

```
modelo |> ols_plot_dffits()
```



12 valores influentes según DFFITS, es decir aquellos que superaron el umbral de 0.29.

```
inf_dffits
```

```
[1] 72 80 84 91 163 199 289 319 327 357 362 374
```


6. Detección de DFBETAS

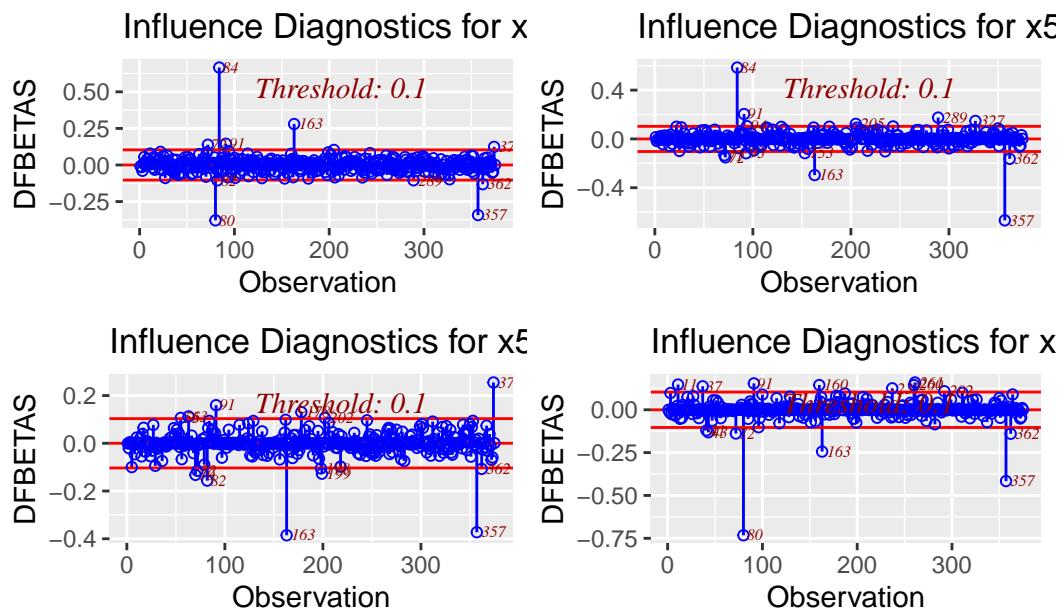
Los DFBETAS permiten evaluar el cambio que tiene cada β al eliminar cada observación.

```
(abs(modelo |> dfbetas()) -> dfbetas  
as.vector(which(dfbetas[,1] >= 2/sqrt(n))) -> dfbeta0  
  
as.vector(which(dfbetas[,2] >= 2/sqrt(n))) -> dfbeta1  
  
as.vector(which(dfbetas[,3] >= 2/sqrt(n))) -> dfbeta2  
  
as.vector(which(dfbetas[,4] >= 2/sqrt(n))) -> dfbeta3  
  
as.vector(which(dfbetas[,5] >= 2/sqrt(n))) -> dfbeta4  
  
as.vector(which(dfbetas[,6] >= 2/sqrt(n))) -> dfbeta5  
  
as.vector(which(dfbetas[,7] >= 2/sqrt(n))) -> dfbeta6  
  
as.vector(which(dfbetas[,8] >= 2/sqrt(n))) -> dfbeta7
```

Se aprecia los dfbetas para cada coeficiente / variable.

```
modelo |> ols_plot_dfbetas()
```





Valores influyentes según DFBETAS: hay observaciones que, al ser retiradas, influyen en varios coeficientes, como por ejemplo 72, 84, 91, 374, 80, 163.

dfbeta0

```
[1] 51 70 71 72 80 84 91 129 153 160 162 199 205 260 289 319 322 326 327  
[20] 357 362 374
```

dfbeta1

```
[1] 72 80 84 91 94 129 163 205 289 319 327 357 362 374
```

dfbeta2

```
[1] 72 80 84 91 94 129 163 205 319 327 357 362 374
```

dfbeta3

```
[1] 27 72 80 84 93 162 163 178 199 201 210 289 357 362 367 374
```

```
dfbeta4
```

```
[1] 72 80 82 84 91 163 289 357 362 374
```

```
dfbeta5
```

```
[1] 55 63 70 72 82 91 163 178 198 199 202 357 362 374
```

```
dfbeta6
```

```
[1] 71 72 84 91 93 94 153 163 205 289 327 357 362
```

```
dfbeta7
```

```
[1] 11 37 41 43 72 80 91 160 163 237 260 261 292 357 362
```


7. Detección de valores influyentes según distancia de Cook

Se halla la distancia de Cook para cada observación del modelo, y luego se verifica cuáles superan el umbral $4/n$.

```
modelo |> cooks.distance() -> cookd  
as.vector(which(cookd > 4/n)) -> inf_cook
```

Gráficamente, observamos que 84 y 357 (que los identificamos como leverage y outliers), presentan las mayores distancias de Cook, es decir son aquellas que, al ser retiradas, cambia más el vector de coeficientes β . Además hay otras observaciones con distancia de Cook algo altas (72, 80, 163, 362, 374)

```
modelo |> ols_plot_cooksd_bar()
```



12 valores influyentes según Distancia de Cook:

```
inf_cook
```

```
[1] 72 80 84 91 163 199 289 319 327 357 362 374
```

8. Detección de valores influyentes según COVRATIO

Se halla el COVRATIO de cada observación del modelo y luego se evalúa, convirtiendo en dos vectores aquellos con mayor ($> 1 + 3k/n$) y menor ($< 1 - 3k/n$) COVRATIO. Finalmente, todo se junta en un solo vector.

```
modelo |> covratio() |> abs() -> covra
as.vector(which(covra > 1+3*k/n)) -> inf_covra1
as.vector(which(covra < 1-3*k/n)) -> inf_covra2
c(inf_covra1, inf_covra2) -> inf_covra
```

9 valores influyentes según COVRATIO:

```
inf_covra
```

```
[1] 185 319 327 80 84 91 163 289 357
```

En resumen, la observación 357 es aquella que es atípica, tiene leverage alto y es influencial en todos los criterios.

```
lista <- list(leverages,
               outliers,
               inf_dffits,
               dfbeta0,dfbeta1,dfbeta2,dfbeta3,dfbeta4,dfbeta5,dfbeta6,dfbeta7,
               inf_cook,
               inf_covra)

inter <- Reduce(intersect, lista)
inter
```

```
[1] 357
```

9. Remoción de los valores leverage, atípicos e influyentes, es decir solo la observación 357.

```
train2 <- train[-c(inter),]
```

10. Creación de un nuevo modelo con el conjunto de datos de entrenamiento “limpio”.

```
modelo2 = lm(y ~ x1 + x2 + x3 + x4 + x5, data = train2)
```

11. Comparación de los reportes del modelo original y el nuevo

```
modelo |> summary()
```

```
Call:  
lm(formula = y ~ x1 + x2 + x3 + x4 + x5, data = train)  
  
Residuals:  
    Min      1Q  Median      3Q     Max  
-11.7807 -1.0193 -0.1207  0.8529 13.9607  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)  
(Intercept) 5.55013   0.42123 13.176 < 2e-16 ***  
x1          1.35969   0.04177 32.553 < 2e-16 ***  
x2         -0.55100   0.06354 -8.672 < 2e-16 ***  
x3          0.02829   0.10227  0.277 0.782246  
x41         0.98436   0.20580  4.783 2.51e-06 ***  
x5B         0.77653   0.27400  2.834 0.004851 **  
x5C        -1.02727   0.26210 -3.919 0.000106 ***  
x5D         1.18452   0.32541  3.640 0.000312 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 1.976 on 367 degrees of freedom  
Multiple R-squared:  0.9966, Adjusted R-squared:  0.9965  
F-statistic: 1.532e+04 on 7 and 367 DF, p-value: < 2.2e-16
```

```
modelo2 |> summary()
```

```
Call:  
lm(formula = y ~ x1 + x2 + x3 + x4 + x5, data = train2)  
  
Residuals:  
    Min      1Q  Median      3Q     Max  
-11.7913 -0.9513 -0.1185  0.8672 17.3718  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)  
(Intercept) 4.65340   0.41271 11.275 < 2e-16 ***  
x1          1.51145   0.04425 34.158 < 2e-16 ***  
x2         -0.77528   0.06690 -11.589 < 2e-16 ***  
x3          0.04942   0.09571  0.516 0.605908  
x41         1.05033   0.19273  5.450 9.29e-08 ***  
x5B         0.87202   0.25665  3.398 0.000754 ***  
x5C        -0.86361   0.24620 -3.508 0.000508 ***  
x5D         1.31120   0.30490  4.300 2.19e-05 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 1.848 on 366 degrees of freedom  
Multiple R-squared:  0.9969, Adjusted R-squared:  0.9969  
F-statistic: 1.688e+04 on 7 and 366 DF, p-value: < 2.2e-16
```

Tendió a aumentar la significancia de las variables, al disminuir la mayoría de los p-valores. Además, cambian los valores de los coeficientes estimados.

12. Selección de variables según R^2 predictivo

Se obtuvo un reporte de indicadores para todos los posibles modelos ($2^5 = 32$), de los cuales aquí se analiza el de R^2 predictivo.

Se observan los modelos con el mayor R^2 predictivo, todos los valores son altos, se elige uno simple y con alto R^2 pred.

```
library(olsrr)
library(dplyr)
ols_step_all_possible(modelo2)$result |> data.frame() -> resultados
resultados |>
  select(n,predrsq,predictors) |>
  arrange(-predrsq) |>
  head()
```

n	predrsq	predictors
1	4	0.9960979 x1 x2 x4 x5
2	5	0.9960822 x1 x2 x3 x4 x5
3	3	0.9958170 x1 x2 x5
4	4	0.9958046 x1 x2 x3 x5
5	3	0.9956196 x1 x2 x4
6	4	0.9956054 x1 x2 x3 x4

Modelo resultante: $Y = f(x_1, x_2, x_5)$

13. Selección de variables según AIC

Del reporte de todos los modelos con sus indicadores, se elige los 6 con menor AIC (penaliza el número de variables).

El modelo con x1, x2, x4 y x5 es el que tiene menor AIC, y no hay un modelo más simple que ese con un AIC tan bajo o con una diferencia de solo 2 unidades.

```
resultados |>
  select(n,aic,predictors) |>
  arrange(aic) |>
  head()
```

n	aic	predictors
1	4 1529.078	x1 x2 x4 x5
2	5 1530.806	x1 x2 x3 x4 x5
3	3 1556.697	x1 x2 x5
4	4 1557.986	x1 x2 x3 x5
5	3 1586.814	x1 x2 x4
6	4 1587.844	x1 x2 x3 x4

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

14. Selección de variables según SBC

Del reporte de todos los modelos con sus indicadores, se elige los 6 con menor SBC (penaliza el número de variables).

Coloca en primer lugar al mismo modelo que el AIC, y del mismo modo no compite con ningún otro.

```
resultados |>
  select(n,sbc,predictors) |>
  arrange(sbc) |>
  head()
```

	n	sbc	predictors
1	4	1560.472	x1 x2 x4 x5
2	5	1566.124	x1 x2 x3 x4 x5
3	3	1584.167	x1 x2 x5
4	4	1589.380	x1 x2 x3 x5
5	3	1606.435	x1 x2 x4
6	4	1611.390	x1 x2 x3 x4

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

15. Selección de variables según SBIC

Del reporte de todos los modelos con sus indicadores, se elige los 6 con menor SBIC (penaliza el número de variables).

Coloca en primer lugar al mismo modelo que el AIC, y del mismo modo no compite con ningún otro, ya que el segundo es más complejo y los demás tienen SBIC muy alto.

```
resultados |>
  select(n,sbic,predictors) |>
  arrange(sbic) |>
  head()
```

n	sbic	predictors
1	4 463.9225	x1 x2 x4 x5
2	5 465.7012	x1 x2 x3 x4 x5
3	3 490.8719	x1 x2 x5
4	4 492.0656	x1 x2 x3 x5
5	3 524.2984	x1 x2 x4
6	4 525.0742	x1 x2 x3 x4

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

16. Selección de variables según Cp de Mallows

Se reporta los 6 modelos con mejor criterio de Cp de Mallows, es decir aquellos cuyo valor se acerque al número de variables.

El mejor modelo incluye las variables x1, x2, x4, x5 igual que los criterios previos, y la diferencia absoluta cp - variables es solo 2.266637

```
resultados |>
  select(n,cp,predictors) |>
  mutate(dif = n-cp,.after=cp) |>
  arrange(abs(dif)) |>
  head()
```

n	cp	dif	predictors
1	4	6.266637	-2.266637 x1 x2 x4 x5
2	5	8.000000	-3.000000 x1 x2 x3 x4 x5
3	3	34.452883	-31.452883 x1 x2 x5
4	4	35.699554	-31.699554 x1 x2 x3 x5
5	4	69.193442	-65.193442 x1 x2 x3 x4
6	3	68.318519	-65.318519 x1 x2 x4

Modelo resultante: $Y = f(X_1, X_2, X_4, X_5)$

17. Selección del modelo según mejores subconjuntos

Se reportan los mejores modelos de 1 variable, de 2 variables, de 3 variables, etc.

Luego, se elige el modelo 4 ($Y \sim x_1 + x_2 + x_4 + x_5$), porque tiene los mejores indicadores:

- R^2 predictivo más alto (aunque empatado con el 5)
- C_p de Mallows más cercano al número de variables ($6.2666 - 4 = 2.2666$)
- AIC más bajo (1529.0782), aunque compite con el modelo 5 (1530.8059) porque difieren en menos de 2 unidades, pero el modelo 4 es más simple
- SBIC más bajo (463.9225), aunque compite con el modelo 5 (465.7012) porque difieren en menos de 2 unidades, pero el modelo 4 es más simple
- SBC más bajo (1560.4723) que todos los demás.

```
modelo2 |> ols_step_best_subset()
```

Best Subsets Regression

Model	Index	Predictors
1		x1
2		x1 x2
3		x1 x2 x5
4		x1 x2 x4 x5
5		x1 x2 x3 x4 x5

Subsets Regression Summary

Model	Adj. R-Square	Pred R-Square	R-Square	C(p)	AIC	SBIC	SBC	MSEP	FPE	HSP
1	0.9949	0.9948	0.9947	239.6075	1709.6139	646.4032	1721.3867	2094.0560	5.6290	0.0151
2	0.9960	0.9960	0.9953	102.0304	1614.3672	551.6919	1630.0642	1618.9601	4.3635	0.0117
3	0.9967	0.9966	0.9958	34.4529	1556.6974	490.8719	1584.1672	1369.2324	3.7203	0.0100
4	0.9969	0.9969	0.9961	6.2666	1529.0782	463.9225	1560.4723	1268.4153	3.4555	0.0093
5	0.9969	0.9969	0.9961	8.0000	1530.8059	465.7012	1566.1242	1270.9456	3.4715	0.0093

AIC: Akaike Information Criteria

SBIC: Sawa's Bayesian Information Criteria

SBC: Schwarz Bayesian Criteria

MSEP: Estimated error of prediction, assuming multivariate normality

FPE: Final Prediction Error

HSP: Hocking's Sp

APC: Amemiya Prediction Criteria

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

18. Selección del mejor modelo según forward selection

La selección via forward va introduciendo variables al modelo. La primera a ser introducida fue X_1 por tener el menor p-valor entre todas las variables, lo que le otorgó la mayor significancia.

Luego, estando ya X_1 en el modelo, la segunda variable en entrar fue X_2 , luego X_4 y finalmente X_5 . Como consecuencia natural y lógica, el AIC fue reduciéndose.

```
modelo2 |> ols_step_forward_p()
```

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	3678.527	3686.375	2613.180	0.00000	0.00000
1	x1	1709.614	1721.387	646.403	0.99486	0.99484
2	x2	1614.367	1630.064	551.692	0.99603	0.99601
3	x4	1586.814	1606.435	524.298	0.99633	0.99631
4	x5	1529.078	1560.472	463.922	0.99691	0.99686

Final Model Output						
Model Summary						
R	0.998	RMSE	1.829			
R-Squared	0.997	MSE	3.346			
Adj. R-Squared	0.997	Coef. Var	1.456			
Pred R-Squared	0.996	AIC	1529.078			
MAE	1.178	SBC	1560.472			

RMSE: Root Mean Square Error
MSE: Mean Square Error
MAE: Mean Absolute Error
AIC: Akaike Information Criteria
SBC: Schwarz Bayesian Criteria

ANOVA						
	Sum of Squares	DF	Mean Square	F	Sig.	
Regression	403616.821	6	67269.470	19727.742	0.0000	
Residual	1251.430	367	3.410			
Total	404868.252	373				

Parameter Estimates							
model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390

x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898
-----	-------	-------	-------	-------	-------	-------	-------

La variable X_1 fue la primera en entrar porque redujo en mayor medida el AIC (más que las otras variables), pasando de 3678 a 1709. La segunda en entrar fue X_2 , reduciendo el AIC de 1709 a 1614, y así sucesivamente entraron X_4 y X_5 .

```
modelo2 |> ols_step_forward_aic()
```

Stepwise Summary

Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	3678.527	3686.375	2613.180	0.00000	0.00000
1	x1	1709.614	1721.387	646.403	0.99486	0.99484
2	x2	1614.367	1630.064	551.692	0.99603	0.99601
3	x5	1556.697	1584.167	490.872	0.99665	0.99661
4	x4	1529.078	1560.472	463.922	0.99691	0.99686

Final Model Output

Model Summary

R	0.998	RMSE	1.829
R-Squared	0.997	MSE	3.346
Adj. R-Squared	0.997	Coef. Var	1.456
Pred R-Squared	0.996	AIC	1529.078
MAE	1.178	SBC	1560.472

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	403616.821	6	67269.470	19727.742	0.0000
Residual	1251.430	367	3.410		
Total	404868.252	373			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390
x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

19. Selección del mejor modelo según backward selection

Comienza con el modelo completo y retira X_3 porque fue la variable con el mayor pvalor. No retira más variables porque las demás no tienen un pvalor alto (solo x_3 tiene $pvalue > 0.05$).

```
modelo2 |> ols_step_backward_p()
```

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Full Model	1530.806	1566.124	465.701	0.99691	0.99685
1	x3	1529.078	1560.472	463.922	0.99691	0.99686

Final Model Output

Model Summary

R	0.998	RMSE	1.829
R-Squared	0.997	MSE	3.346
Adj. R-Squared	0.997	Coef. Var	1.456
Pred R-Squared	0.996	AIC	1529.078
MAE	1.178	SBC	1560.472

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	403616.821	6	67269.470	19727.742	0.0000
Residual	1251.430	367	3.410		
Total	404868.252	373			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390
x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898

Comienza con el modelo completo y solo retira X_3 porque es la única, que al ser retirada, el AIC disminuye.

```
modelo2 |> ols_step_backward_aic()
```

Stepwise Summary

Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Full Model	1530.806	1566.124	465.701	0.99691	0.99685
1	x3	1529.078	1560.472	463.902	0.99691	0.99686

Final Model Output

Model Summary

R	0.998	RMSE	1.829
R-Squared	0.997	MSE	3.346
Adj. R-Squared	0.997	Coef. Var	1.456
Pred R-Squared	0.996	AIC	1529.078
MAE	1.178	SBC	1560.472

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	403616.821	6	67269.470	19727.742	0.0000
Residual	1251.430	367	3.410		
Total	404868.252	373			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390
x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

20. Selección del mejor modelo según stepwise selection

El método stepwise agrega y retira variables, pero en este caso solo agrega por lo que el resultado es equivalente al de forward selection.

```
modelo2 |> ols_step_both_p()
```

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	3678.527	3686.375	2613.180	0.00000	0.00000
1	x1 (+)	1709.614	1721.387	646.403	0.99486	0.99484
2	x2 (+)	1614.367	1630.064	551.692	0.99603	0.99601
3	x4 (+)	1586.814	1606.435	524.298	0.99633	0.99631
4	x5 (+)	1529.078	1560.472	463.922	0.99691	0.99686

Final Model Output

Model Summary			
R	0.998	RMSE	1.829
R-Squared	0.997	MSE	3.346
Adj. R-Squared	0.997	Coef. Var	1.456
Pred R-Squared	0.996	AIC	1529.078
MAE	1.178	SBC	1560.472

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	403616.821	6	67269.470	19727.742	0.0000
Residual	1251.430	367	3.410		
Total	404868.252	373			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390
x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898

El método stepwise agrega y retira variables, pero en este caso solo agrega por lo que el resultado es equivalente al de forward selection.

```
modelo2 |> ols_step_both_aic()
```

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	3678.527	3686.375	2613.180	0.00000	0.00000
1	x1 (+)	1709.614	1721.387	646.403	0.99486	0.99484
2	x2 (+)	1614.367	1630.064	551.692	0.99603	0.99601
3	x5 (+)	1556.697	1584.167	490.872	0.99665	0.99661
4	x4 (+)	1529.078	1560.472	463.922	0.99691	0.99686

Final Model Output

Model Summary			
R	0.998	RMSE	1.829
R-Squared	0.997	MSE	3.346
Adj. R-Squared	0.997	Coef. Var	1.456
Pred R-Squared	0.996	AIC	1529.078
MAE	1.178	SBC	1560.472

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	403616.821	6	67269.470	19727.742	0.0000
Residual	1251.430	367	3.410		
Total	404868.252	373			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig	lower	upper
(Intercept)	4.646	0.412		11.275	0.000	3.835	5.456
x1	1.511	0.044	1.506	34.192	0.000	1.425	1.598
x2	-0.775	0.067	-0.511	-11.600	0.000	-0.907	-0.644
x5B	0.883	0.256	0.012	3.454	0.001	0.380	1.385
x5C	-0.872	0.245	-0.012	-3.554	0.000	-1.355	-0.390
x5D	1.300	0.304	0.014	4.279	0.000	0.703	1.898
x41	1.057	0.192	0.016	5.500	0.000	0.679	1.435

Modelo resultante: $Y = f(x_1, x_2, x_4, x_5)$

21. Uso del testing

Hasta este punto, el modelo candidato con mayor fuerza es:

$$Y = f(x_1, x_2, x_4, x_5)$$

Lo vamos a poner a prueba.

Construimos el modelo3:

```
modelo3 = lm(y ~ x1 + x2 + x4 + x5, data = train2)
```

Obtenemos las predicciones del modelo3 en el training y el testing.

```
pred_train <- predict(modelo3, newdata = train2)
pred_test <- predict(modelo3, newdata = test)
```

Defino métricas para evaluar las predicciones:

```
metricas <- function(y, yhat){
  rmse <- sqrt(mean((y - yhat)^2)) # root mean square error
  mae <- mean(abs(y - yhat)) # mean absolute error
  r2 <- 1 - sum((y - yhat)^2)/sum((y - mean(y))^2) # R^2
  c(RMSE = rmse, MAE = mae, R2 = r2)
}
```

Calculo las métricas en el training y testing, esperando que no haya una discrepancia muy grande. De haber discrepancia, significaría que el modelo funciona bien en el training, pero no en el testing (sobreajuste).

```
m_train <- metricas(train2$y, pred_train)
m_test <- metricas(test$y, pred_test)
```

```
m_train
```

RMSE	MAE	R2
1.829227	1.177658	0.996909

```
m_test
```

RMSE	MAE	R2
2.6027405	1.3958899	0.9931682

Lo usual es que el RMSE y el MAE aumenten en el testing (un aprox más de 25% a 50%), y que el R2 baje.

En este caso, la variación es pequeña, por lo que el modelo estaría funcionando bien en el conjunto testing.

21. Interpretación de coeficientes del mejor modelo

```
modelo3 |> coef()
```

(Intercept)	x1	x2	x41	x5B	x5C
4.6455416	1.5114489	-0.7752010	1.0567180	0.8827581	-0.8721613
x5D					
1.3004364					

$$\hat{Y} = 4.646 + 1.511x_1 - 0.7752x_2 + 1.0567x_4 + 0.883x_{5b} - 0.872x_{5c} + 1.3x_{5d}$$

Variable respuesta: Precio de venta (miles de USD)

Variables explicativas:

- x1: Área construida, en metros cuadrados
- x2: Índice de calidad constructiva (z-score), es un puntaje técnico de materiales y acabados.
- x3: Intensidad de publicidad digital (z-score), es una medida de exposición en portales y anuncios.
- x4: Tiene cochera (0: No, 1: Sí)
- x5: Zona de la ciudad (A = Zona periférica, B = Zona intermedia, C = Zona comercial, D = Zona premium)

$\hat{\beta}_0 = 4.646$ no tiene interpretación porque el área no puede ser de 0 m^2

$\hat{\beta}_1 = 1.511$: por cada metro cuadrado adicional de área construida, el precio promedio de venta aumenta en 1.511 miles de dólares, manteniendo constante las demás variables.

$\hat{\beta}_2 = -0.7752$: Un aumento de una unidad en el índice de calidad constructiva se asocia con una disminución promedio de 0.7752 miles de dólares en el precio de venta, manteniendo constantes las demás variables.

$\hat{\beta}_4 = 1.0567$: los inmuebles que tienen cochera presentan en promedio un precio de venta 1.0567 miles de dólares mayor que aquellos que no tienen cochera, manteniendo constantes las demás variables.

$\hat{\beta}_{5b} = 0.883$: los inmuebles ubicados en la zona intermedia tienen en promedio un precio de venta 0.883 miles de dólares mayor que los ubicados en la zona periférica, manteniendo constantes las demás variables.

$\hat{\beta}_{5c} = -0.872$: los inmuebles ubicados en la zona comercial tienen en promedio un precio de venta 0.872 miles de dólares menor que los ubicados en la zona periférica, manteniendo constantes las demás variables.

$\hat{\beta}_{5d} = 1.3$: los inmuebles ubicados en la zona premium tienen en promedio un precio de venta 1.3 miles de dólares mayor que los ubicados en la zona periférica, manteniendo constantes las demás variables.

¿Cuál es la ecuación estimada de regresión para un inmueble con cochera en la zona periférica?

$$\hat{Y} = 4.646 + 1.511x_1 - 0.7752x_2 + 1.0567$$

$$\hat{Y} = 5.7207 + 1.511x_1 - 0.7752x_2$$