

$H_0: \beta_1 = 0 \rightarrow$  no existe relación lineal entre  $X$  e  $Y$

$H_1: \beta_1 \neq 0 \rightarrow$  existe relación lineal entre  $X$  e  $Y$  (Variab. Regres.  $\rightarrow$  Variab. Error)

$F_{calc}$  : estadístico de prueba

Variabilidad  $\begin{cases} \text{Regresión} \checkmark \\ \text{Error} \checkmark \end{cases}$

Fuente	GL	SC	CM	$F_{cal}$
✓ Regresión	1	$SC_{Reg}$	$CM_{Reg}$	$CM_{Reg} / CM_{Error}$
✓ Error	$n - 2$	$SC_{Error}$	$CM_{Error}$	
Total	$n - 1$	$SC_{Total}$		

$$CM_{Error} = \hat{\sigma}^2$$

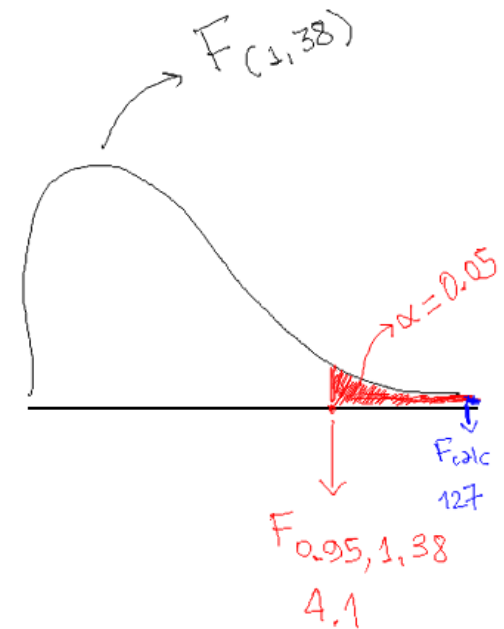
(Varianza estimado del modelo)

$$H_0 : \beta_1 = 0 \quad \text{vs.} \quad H_1 : \beta_1 \neq 0 \quad \alpha = 0.05$$

```
anova = aov(y ~ x) |> tidy()
anova
```

# A tibble: 2 x 6

	term	df	sumsq	meansq	statistic	p.value
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	x	1	267.	267.	127.	1.16e-13
2	Residuals	38	80.2	2.11	NA	NA



~~mm~~  $\rightarrow \alpha$

~~mm~~  $\rightarrow p\text{-value}$

$p\text{-value} < \alpha \Rightarrow \text{Rech. } H_0$


$$H_0: \beta_0 \geq 4$$

$$H_1: \beta_0 < 4$$

$$\alpha = 0.05$$

$$t_{calc} = \frac{\hat{\beta}_0 - b}{s_{\hat{\beta}_0}} \sim t_{n-2}$$

$$t_{calc} = \frac{8.99 - 4}{0.588} = 8.5$$



$t_{calc}$  cae en la zona de No rechazo de  $H_0$   
 $pV > \alpha \Rightarrow$  No se rechaza  $H_0$

```
library(broom)
modelo |> tidy()
```

# A tibble: 2 x 5

term	estimate	std.error	statistic	p.value
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 (Intercept)	8.99	0.588	15.3	8.13e-18
2 horas_estudio	0.641	0.0570	11.3	1.16e-13

$$H_0: \beta_1 \leq 0.7$$

$$H_1: \beta_1 > 0.7$$

$$t_{calc} = \frac{\hat{\beta}_1 - b}{s_{\hat{\beta}_1}} \sim t_{n-2}$$

$$H_0: \beta_0 = 10$$

$$H_1: \beta_0 \neq 10$$

$$t_{calc} = \frac{\hat{\beta}_0 - b}{s_{\hat{\beta}_0}} \sim t_{n-2}$$

## Coeficiente de determinación

► El coeficiente de determinación se define como:

$$R^2 = \frac{SC_{\text{Reg}}}{SC_{\text{Total}}}$$

$$SC_{\text{Total}} = SC_{\text{Reg}} + SC_{\text{Error}}$$

Coeficiente de no determinación:  $1 - R^2$  : % de variabilidad de  $Y$  explicada por otros factores distintos a  $X$

```
rsq      = anova$sumsq[1]/(anova$sumsq[1] + anova$sumsq[2])  
adjrsq   = 1 - (1-rsq)*(n-1)/(n-1-1)  
summary(modelo)$r.squared →  $R^2$  ✓
```

```
[1] 0.7691646
```

```
summary(modelo)$adj.r.squared →  $R^2_{aj}$  ✓
```

```
[1] 0.76309
```

$$R^2 = 0.769 = 76.9\%$$

$$\rightarrow R^2_{aj} = 0.763 = 76.3\%$$

## Estimación de la media y predicción de un valor individual

$$(\hat{\mu})$$

$$(\hat{y}_0)$$

$$\bar{y} \sim N(\mu, \sigma^2/n)$$

### Estimación

La media estimada de  $Y$  para un valor dado de  $X = x$  es:

$$\hat{\mu} = \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Su varianza estimada es:

$$\widehat{Var}(\hat{\mu}) = \hat{\sigma}^2 \left( \frac{1}{n} + \frac{(x - \bar{x})^2}{SC_X} \right) = \frac{\hat{\sigma}^2}{n} + \frac{\hat{\sigma}^2 (x - \bar{x})^2}{SC_X}$$

### Predicción

La predicción para una nueva observación  $Y_0$  viene dada por:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$Var(\hat{y}_0) > Var(\hat{\mu})$$

con varianza estimada:

$$\widehat{Var}(\hat{y}_0) = \hat{\sigma}^2 \left( 1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{SC_X} \right)$$

```
modelo |> predict(newdata = data.frame(1, horas_estudio = x0),
                  interval = "confidence")
```

	fit	lwr	upr
1	14.12054	13.62429	14.61678

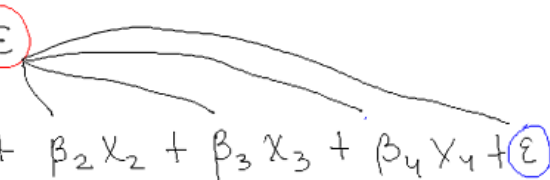
$$IC(\mu|x = 8) = (13.62, 14.62)$$

```
modelo |> predict(newdata = data.frame(1, horas_estudio = x0),
                  interval = "prediction")
```

	fit	lwr	upr
1	14.12054	11.13748	17.1036

$$IP(Y|x = 8) = (11.14, 17.10) \Rightarrow \text{Intervalo más ancho más variable}$$


## Regresión Lineal Simple → Regresión Lineal Múltiple

$$y = \beta_0 + \beta_1 x + \varepsilon$$
$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$$
A diagram showing the expansion of the error term  $\varepsilon$ . In the first equation,  $\varepsilon$  is circled in red. Four arrows originate from this circle and point to the  $\varepsilon$  term in the second equation, which is circled in blue. The second equation also has its  $\varepsilon$  term circled in blue.

### Ejemplo aplicado

Se busca estudiar el efecto lineal de la edad (años), el sexo (femenino / masculino) y los años de educación sobre el sueldo mensual (en miles de soles). Adicionalmente, se incorpora una variable ficticia  $X_4$ , generada al azar, para evaluar su comportamiento en el modelo. Se dispone de una muestra de  $n = 24$  observaciones.

Una primera etapa del análisis consiste en explorar la relación entre la variable respuesta y cada variable explicativa mediante diagramas de dispersión.



## Regresión Lineal Múltiple

$$\mathbf{y}_{n \times 1} = \mathbf{X}_{n \times (p+1)} \boldsymbol{\beta}_{(p+1) \times 1} + \boldsymbol{\varepsilon}_{n \times 1}$$

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$\underbrace{\quad}_{X_1} \quad \underbrace{\quad}_{X_2}$

$\mathbf{X}$ : matriz del modelo

$$y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \dots + \beta_p x_{1p} + \varepsilon_1$$

$$y_1 = \beta_0 + \sum_{j=1}^p \beta_j x_{1j} + \varepsilon_1$$



$$\hat{\beta} = (\underbrace{\mathbf{X}'\mathbf{X}}_{\substack{(p+1) \times n \quad n \times (p+1) \\ (p+1) \times (p+1)}})^{-1} \underbrace{\mathbf{X}'\mathbf{y}}_{(p+1) \times 1}$$

$$\mathbf{X}_{n \times (p+1)} \quad \mathbf{y}_{n \times 1}$$

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix}$$

$$\text{Var}(\hat{\beta}) = \underbrace{\sigma^2}_{\text{número}} (\underbrace{\mathbf{X}'\mathbf{X}}_{(p+1) \times (p+1)})^{-1} = \sigma^2 \begin{pmatrix} \end{pmatrix}_{(p+1) \times (p+1)}$$

$$\text{Ej m: } \hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}, \quad \text{Var}(\hat{\beta}) = \sigma^2 \begin{pmatrix} \end{pmatrix}_{3 \times 3} = \begin{pmatrix} \text{Var}(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_2) \\ \cdot & \text{Var}(\hat{\beta}_1) & \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \\ \cdot & \cdot & \text{Var}(\hat{\beta}_2) \end{pmatrix}$$

simétrica

```
library(dplyr) ✓
y = datos$Sueldo ✓
X = model.matrix(Sueldo~Educacion+Sexo+Edad+X4, data=datos)
solve(t(X)%*%X)%*%t(X)%*%y
```

modelo

→ genera la matriz X

inversa  
transpuesta

[,1]

$$(X'X)^{-1}X'y$$

(Intercept) -0.73053615 →  $\hat{\beta}_0$   
 Educacion 0.15695057 →  $\hat{\beta}_1$   
 SexoM 0.82211261 →  $\hat{\beta}_2$   
 Edad 0.10462774 →  $\hat{\beta}_3$   
 X4 -0.04537505 →  $\hat{\beta}_4$

```
modelo = lm(Sueldo ~ ., datos)
(beta = coef(modelo))
```

incluir todas las variables

(Intercept)	Educacion	SexoM	Edad	X4
-0.73053615 ✓	0.15695057 ✓	0.82211261 ✓	0.10462774 ✓	-0.04537505 ✓

$$E_j m: \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \quad \text{Var}(\hat{\beta}) = \begin{pmatrix} \text{Var}(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \text{Var}(\hat{\beta}_1) \end{pmatrix}$$