

```
modelo = lm(Sueldo ~ ., datos)
(beta = coef(modelo))
```

$$\begin{cases} F=0 \\ M=1 \end{cases}$$

(Intercept)	Educacion	SexoM	Edad	X4
-0.73053615	0.15695057	0.82211261	0.10462774	-0.04537505

$$\hat{Y} = -0.731 + 0.157 \text{Educación} + 0.822 \text{SexoM} + 0.105 \text{Edad} - 0.045 X_4$$

miles \$ miles \$ / años años miles \$ miles \$ / año años miles \$ /

$\hat{\beta}_0 = -0.731$: No tiene interpretación lógica porque Edad $\neq 0$ y el sueldo no puede ser negativo

$\hat{\beta}_1 = 0.157$: por cada año adicional de educación, el sueldo promedio se incrementa en 0.157 miles de soles, manteniendo las demás características en valores fijos

$$- \quad \hat{Y} = -0.73 + 0.157 \text{Educ} + 0.822 \text{SexoM} + 0.105 \text{Edad} - 0.045 X_4$$

$$- \quad \hat{Y}^* = -0.73 + 0.157 (\text{Educ} + 1) + 0.822 \text{SexoM} + 0.105 \text{Edad} - 0.045 X_4$$

$$\hat{Y}^* - \hat{Y} = 0.157$$

$\hat{\beta}_3 = 0.105$: por cada año adicional de edad, el sueldo promedio aumenta en 0.105 miles de soles, manteniendo constantes la educación, el sexo y X_4 .

$\hat{\beta}_2 = 0.822$: el sueldo promedio de los hombres ($\text{Sexo}=1$) supera en 0.822 miles de soles al de las mujeres ($\text{Sexo}=0$), manteniendo constante la edad, la educación y X_4 .

Estimación intervalar

Si g_{ii} es el elemento i -ésimo de la diagonal de $(X'X)^{-1}$, entonces:

$$IC(\beta_i) = \hat{\beta}_i \pm t_{1-\alpha/2, n-k} \hat{\sigma} \sqrt{g_{ii}}$$

$K = \# \text{ coeficientes}$
 $p = \# \text{ variables}$

```
G = solve(t(X)%*%X)
g = G |> diag()
n = datos |> nrow() ✓
k = beta |> length() ✓ # coef
valt = qt(0.975, "24-5")
beta = vvalt*sigma*sqrt(g)
```

(Intercept)	Educacion	SexoM	Edad	X4
-2.58809073	0.02638407	-0.18289392	0.04174457	-0.12999986

beta + vvalt*sigma*sqrt(g)

(Intercept)	Educacion	SexoM	Edad	X4
1.12701843	0.28751706	1.82711914	0.16751091	0.03924976

$$Y_i = \beta_0 + (\beta_1 X_{1,i} + \beta_2 X_{2,i} + \cdots + \beta_p X_{p,i}) + \varepsilon_i, \quad i = 1, \dots, n$$

$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0 \rightarrow Y_i = \beta_0 + \varepsilon$: las X no influyen linealmente en Y
 $H_1 : \text{Al menos un } \beta_j \neq 0$

Variancia	Regresión	GL	SC	CM	F _{calc}
	Error	K-1	SC _{Reg}	CM _{Reg}	CM _{Reg} /CM _E
		n-K	SC _E	CM _E	

vector de datos
vector de 1s

$$\mathbf{1}' = (1 \ 1 \ \dots \ 1)$$

$$SC_{Total} = (\mathbf{y} - \bar{y}\mathbf{1})'(\mathbf{y} - \bar{y}\mathbf{1}) \quad \bar{y} = \frac{1}{n} \mathbf{1}' \mathbf{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$(1 \ 1 \ \dots \ 1) \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \sum_{i=1}^n y_i$$

$$SC_{Reg} = (\hat{\mathbf{y}} - \bar{y}\mathbf{1})'(\hat{\mathbf{y}} - \bar{y}\mathbf{1})$$

$$SC_{Error} = \mathbf{e}'\mathbf{e} = (\mathbf{y} - \hat{\mathbf{y}})'(\mathbf{y} - \hat{\mathbf{y}})$$

$$SC_{Total} = (\mathbf{y} - \bar{\mathbf{y}}\mathbf{1})'(\mathbf{y} - \bar{\mathbf{y}}\mathbf{1}) \quad \bar{\mathbf{y}} = \frac{1}{n}\mathbf{1}'\mathbf{y}$$

$$SC_{Reg} = (\hat{\mathbf{y}} - \bar{\mathbf{y}}\mathbf{1})'(\hat{\mathbf{y}} - \bar{\mathbf{y}}\mathbf{1})$$

$$\underline{SC_{Error}} = \mathbf{e}'\mathbf{e} = (\mathbf{y} - \hat{\mathbf{y}})'(\mathbf{y} - \hat{\mathbf{y}})$$

Sumas de cuadrados

```
uno = rep(1,n)
ybarra = as.numeric(1/n*(uno)%%y)
yhat = predict(modelo)
SCTotal = t(y - ybarra*uno)%%(y - ybarra*uno)
```

```
[,1]
[1,] 103.0379
SCReg = t(yhat - ybarra*uno)%%(yhat - ybarra*uno)
```

```
[,1]
[1,] 78.57194
SCError = t(y - yhat)%%(y-yhat)
```

```
[,1]
[1,] 24.46592
```

|| teams.microsoft.com está compartiendo

Estadístico de prueba

(Fcalc = CMReg / CMError)

```
[,1]
[1,] 15.25455
```

Valor crítico:


qf(0.95, 4, 19)

[1] 2.895107

Pvalor:

pf(Fcalc, 4, 19, lower.tail = F)

```
[,1]
[1,] 9.638667e-06
```



Prueba de hipótesis individual

$$H_0 : \beta_i = 0$$

$$H_1 : \beta_i \neq 0$$

```
library(broom)
modelo |> tidy()
```

A tibble: 5 x 5

term	estimate	std.error	statistic	p.value
1 (Intercept)	-0.731	0.887	-0.823	0.421
2 Educacion	0.157	0.0624	2.52	0.0210
3 SexoM	0.822	0.480	1.71	0.103
4 Edad	0.105	0.0300	3.48	0.00249
5 X4	-0.0454	0.0404	-1.12	0.276

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

$$\alpha = 0.05$$

$$pV = 0.021$$

Se rechaza H_0

Los años de educación
tienen influencia
lineal sobre el sueldo

$$H_0 : \beta_4 = 0$$

$$H_1 : \beta_4 \neq 0$$

$$\alpha = 0.05$$

$$pV = 0.246$$

No se rechaza H_0

X_4 no tiene influencia
lineal sobre el sueldo

```
library(broom)
modelo |> tidy()
```

A tibble: 5 x 5


	term	estimate	std.error	statistic	p.value
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	(Intercept)	-0.731	0.887	-0.823	0.421
2	Educacion	0.157	0.0624	2.52	0.0210
3	SexoM	0.822	0.480	1.71	0.103
4	Edad	0.105	0.0300	3.48	0.00249
5	X4	-0.0454	0.0404	-1.12	0.276

$$H_0: \beta_3 \leq 0.1$$

$$H_1: \beta_3 > 0.1$$

$$\alpha = 0.05$$

$$t_{\text{calc}} = \frac{\hat{\beta}_3 - \beta_3}{S_{\beta_3}} = \frac{0.105 - 0.1}{0.03} = 0.167$$



No se rechaza H_0

No existe evidencia estadística para afirmar que por cada año adicional de edad, el sueldo promedio se incremente en más de 0.1 miles de soles.

Siempre sube $\rightarrow R^2$

$$Y \sim X_1 \quad 0.47$$

$$Y \sim X_1 + X_2 \quad 0.76 \quad 0.75$$

$$Y \sim X_1 + X_2 + \cancel{X_3} \quad 0.77 \quad 0.74$$

R^2_{adj} → puede disminuir si la variable que se añade

0.465 no contribuye al modelo

$$AIC = -2\ln(L) + 2k \quad \xrightarrow{\text{# coeficientes}}$$

↓
↳ Verosimilitud (Likelihood)

Busca modelos parsimoniosos

Nº Variables	L	AIC
i) 2	30	$-2 \ln(30) + 2 \times 2 = -6.8 + 4 = -2.8$
ii) 5	45	$-2 \ln(45) + 2 \times 5 = -7.6 + 10 = 2.4$
iii) 9	48	$-2 \ln(48) + 2 \times 9 = -7.7 + 18 = 10.3$

Estimación de la media de la respuesta

Para un vector de valores explicativos $\mathbf{x} := (1 \ x_1 \ x_2 \dots x_p)$

$$\hat{\mu} = \hat{y} = \mathbf{x}' \hat{\beta} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p$$

Estimación del sueldo medio para una mujer de 35 años de edad, con 12 años de educación, y tomando $X_4 = 1$.

Puntual:

$x_0 = c(1, 12, 0, 35, 1)$ el orden de los datos debe ser el mismo que se definió en el modelo

$yest = x0 * %beta$

$yest$


[,1]

[1,] 4.769467

model = lm(Sueldo ~ ., datos)
(beta = coef(model)) todas las variables

Intervalo de confianza:

$$IC(\mu|\mathbf{x}) = \hat{\mu} \pm t_{1-\alpha/2, n-k} \sqrt{\hat{\sigma}^2 \mathbf{x}' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}}$$



```
predict(modelo,
        data.frame(Educacion = 12,
                    Sexo = "F",
                    Edad = 35,
                    X4 = 1),
        interval = "confidence")
```

	fit	lwr	upr
1	4.769467	3.944129	5.594804

```
predict(modelo,
        data.frame(Educacion = c(12, 7),
                    Sexo = c("F", "M"),
                    Edad = c(35, 28),
                    X4 = c(1, -2)),
        interval = "confidence")
```

	fit	lwr	upr
1	4.769467	3.944129	5.594804
2	4.210557	3.177470	5.243645

Intervalo de confianza:

$$IC(\mu|\mathbf{x}) = \hat{\mu} \pm t_{1-\alpha/2, n-k} \sqrt{\hat{\sigma}^2 \mathbf{x}'(X'X)^{-1}\mathbf{x}}$$

Intervalo de predicción:

$$IP(y|\mathbf{x}) = \hat{y}_0 \pm t_{1-\alpha/2, n-k} \sqrt{\hat{\sigma}^2 (1 + \mathbf{x}'(X'X)^{-1}\mathbf{x})}$$

$$IC(\mu|\mathbf{x}) = (3.94, 5.59)$$

$$IP(y|\mathbf{x}) = (2.255, 7.284)$$

Residuales

El vector de residuales es:

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y} = \mathbf{I}\mathbf{y} - \mathbf{H}\mathbf{y}$$

matriz identidad
matriz hat

donde:

$$X \quad n \times (p+1)$$

$$H = X(X'X)^{-1}X'$$

$n \times (p+1)$ $(p+1) \times n \times n \times (p+1)$ $(p+1) \times n$
 $(p+1) \times (p+1)$

$$H \quad n \times n$$