

DFBETAS

De manera similar a la distancia de Cook, permite evaluar cuánto cambia el j -ésimo coeficiente de regresión si se elimina la i -ésima observación. Se tiene que:

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i\epsilon_i}{1 - h_{ii}}$$

donde:

- ▶ $\hat{\beta}$ es la estimación de β en el conjunto de datos completo
- ▶ $\hat{\beta}_{(i)}$ cuando se elimina la i -ésima observación

matriz del modelo
 i -ésima fila de \mathbf{X}
 i -ésimo error
 i -ésimo valor hat
 i -ésimo valor de la diagonal de la matriz hat

	cook			
obs	D_i	DFBeta ₀	DFBeta ₁	DFBeta ₂
1	D_1	•	•	•
2	D_2	•	•	•
3	D_3	•	•	•
⋮	⋮			
n	D_n	•	•	•

$n \times k$
 \downarrow
 # observaciones

\nearrow
 # coeficientes

	β_0	β_1
	(Intercept)	x
1	-0.275691211	0.1929583403
2	-0.123523176	0.0672754784
3	-0.006071150	-0.0102087577
4	-0.203638872	0.1288329898
5	-0.077603339	0.0194540553
6	-0.075649967	0.0321127060
7	-0.018349996	-0.0004230407
8	4.053966371	-1.7208709421
9	-0.119122513	0.0648787078
10	0.639178659	-0.9865042898
11	-0.018923427	0.0065534903
12	0.003665428	0.0156715670

12x2

DFBeta₀ más alejado de 0 : 8

DFBeta₁ más alejado de 0 : 8

DFFITS

¿Qué sucede con el valor de \hat{y} si se elimina la i -ésima observación?

$$DFFITS_i = \frac{\hat{y}_i - \hat{y}_{(i)}}{\sqrt{\hat{\sigma}_{(i)}^2 h_{ii}}} = t_i \times \sqrt{\frac{h_{ii}}{1 - h_{ii}}}$$

$\hat{y}_i - \hat{y}_{(i)}$
 $\hat{\sigma}_{(i)}^2$ ← CME al quitar la i -ésima obs
 h_{ii} ← i -ésimo valor diagonal hat

obs	\hat{y}
1	\hat{y}_1
2	\hat{y}_2
3	\hat{y}_3
:	:
n	\hat{y}_n

obs	
1	$\hat{y}_{(1)}$
2	
3	
:	:
n	

$$DFFITs_i = \frac{\hat{y}_i - \hat{y}_{(i)}}{\sqrt{\hat{\sigma}_{(i)}^2 h_{ii}}} = t_i \times \sqrt{\frac{h_{ii}}{1 - h_{ii}}}$$

```

modelo |> predict() -> y_pred
x_sin1 = x[-1]
y_sin1 = y[-1]
modelo_sin1 = lm(y_sin1 ~ x_sin1, data.frame(x_sin1, y_sin1))
modelo_sin1 |> predict(data.frame(x_sin1 = x[1])) -> y_pred_sin
(modelo_sin1 |> sigma())**2 -> cme_sin
modelo |> hatvalues() -> h
(y_pred[1] - y_pred_sin[1]) / sqrt(cme_sin * h[1])

```

```

1
-0.2832984 ✓

```

```

modelo |> rstudent() -> t
t[1] * sqrt(h[1] / (1 - h[1]))

```

```

1
-0.2832984 ✓

```

COVRATIO

$$COVRATIO_i = \frac{|\hat{\sigma}_{(i)}^2 (\mathbf{X}'_{(i)} \mathbf{X}_{(i)})^{-1}|}{|\hat{\sigma}^2 (\mathbf{X}' \mathbf{X})^{-1}|} = \left(\frac{\hat{\sigma}_{(i)}^2}{\hat{\sigma}^2} \right)^k \left(\frac{1}{1 - h_{ii}} \right)$$

¿Qué sucede si $COVRATIO > 1$? ¿Y si es menor a 1? ¿Qué papel cumplen los leverages en los COVRATIOS?

$COVRATIO > 1 \Rightarrow |\hat{\sigma}_{(i)}^2 (\mathbf{X}'_{(i)} \mathbf{X}_{(i)})^{-1}| > |\hat{\sigma}^2 (\mathbf{X}' \mathbf{X})^{-1}|$ Al retirar la i -ésima observación, la variabilidad de $\hat{\beta}$ aumenta

$COVRATIO < 1 \Rightarrow |\hat{\sigma}_{(i)}^2 (\mathbf{X}'_{(i)} \mathbf{X}_{(i)})^{-1}| < |\hat{\sigma}^2 (\mathbf{X}' \mathbf{X})^{-1}|$ Al retirar la i -ésima observación, la variabilidad de $\hat{\beta}$ disminuye

leverage (h_{ii}) \uparrow COVRATIO \uparrow

Resumen proporcionado por R:

```
modelo |> influence.measures()
```

|| teams.microsoft.com está compartiendo

Influence measures of

lm(formula = y ~ x) :

	<i>dfbeta0</i> dfb.1_	<i>dfbeta1</i> dfb.x	<i>r</i> dffit	<i>covratio</i> cov.r		<i>hi</i> hat	inf
1	-0.27569	0.192958	-0.2833	1.32982	0.042527	0.1554	
2	-0.12352	0.067275	-0.1390	1.33788	0.010548	0.1088	
3	-0.00607	-0.010209	-0.0281	1.36340	0.000439	0.0960	
4	-0.20364	0.128833	-0.2163	1.32335	0.025104	0.1292	
5	-0.07760	0.019454	-0.1122	1.31126	0.006896	0.0859	
6	-0.07565	0.032113	-0.0938	1.33808	0.004838	0.0944	
7	-0.01835	-0.000423	-0.0337	1.34310	0.000628	0.0833	
8	4.05397	-1.720871	5.0243	0.00175	0.502575	0.0944	*
9	-0.11912	0.064879	-0.1340	1.34113	0.009821	0.1088	
10	0.63918	-0.986504	-1.0389	7.79559	0.586971	0.8482	*
11	-0.01892	0.006553	-0.0251	1.35387	0.000350	0.0894	
12	0.00367	0.015672	0.0339	1.37800	0.000637	0.1060	