

Y	X_1	X_2	D_1	D_2
14	6	A	0	1
17	8	A	0	1
9	5	B	0	0
12	5	M	1	0
16	10	A	0	1
24	11	B	0	0

$$Y = f(X_1, D_1, D_2)$$

Categoría (código)	D_1	D_2
Bajo (0)	0	0
Medio (1)	1	0
Alto (2)	0	1

$$D_1 = \begin{cases} 1, & \text{Categ} = \text{Medio} \\ 0, & \text{Categ} \neq \text{Medio} \end{cases}$$

$$D_2 = \begin{cases} 1, & \text{Categ} = \text{Alto} \\ 0, & \text{Categ} \neq \text{Alto} \end{cases}$$

¿Qué pasa con el ANVA si categorizamos una variable cuantitativa?

Y	X ₁	N ₁ <small>0-4 B 5-6 M 7+ A</small>	D ₁	D ₂
14	5	M	1	0
17	6	M	1	0
9	4	B	0	0
12	5	M	1	0
8	2	B	0	0
20	7	A	0	1

Modelo original: $Y \sim X_1$ → want

FV	GL	SC	CM	F _{calc}
Reg	1			↑
Error	4	SCE	SCE/4	
Total	5			

Modelo nuevo: $Y \sim D_1 + D_2$

FV	GL	SC	CM	F _{calc}
Reg	2	.		↓
Error	3	SCE	SCE/3	
Total	5			

Factor dicotómico

Solo un factor dicotómico

Suponga el siguiente modelo, donde X_1 es una variable dicotómica, que toma los valores 0 y 1:

$$Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Si $X_1 = 0$, entonces $Y = \beta_0 + \epsilon$, mientras que si $X_1 = 1$, $Y = \beta_0 + \beta_1 + \epsilon$

Este modelo es equivalente a una prueba t de comparación de medias independientes con varianzas homogéneas, ¿cuáles serían las hipótesis del contraste?

$$\mu_2 = \beta_0 + \epsilon$$

$$\mu_1 = \beta_0 + \beta_1 + \epsilon$$

$$\mu_1 - \mu_2 = \beta_1$$

```
modelo1 |> summary()
```

Call:

```
lm(formula = Nota ~ Turno, data = datosA)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-8.0667	-2.2500	-0.0667	1.9333	6.7500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	16.0667	0.9538	16.844	3.72e-15 ***
TurnoNoche	-3.8167	1.4308	-2.668	0.0132 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.694 on 25 degrees of freedom

Multiple R-squared: 0.2216, Adjusted R-squared: 0.1904

F-statistic: 7.116 on 1 and 25 DF, p-value: 0.01321

```
t.test(Nota~Turno,datosA,var.equal=TRUE)
```

Two Sample t-test

data: Nota by Turno

t = 2.6676, df = 25, p-value = 0.01321

alternative hypothesis: true difference in means between group Mañana and 95 percent confidence interval:

0.8699427 6.7633906

sample estimates:

mean in group Mañana	mean in group Noche
16.06667	12.25000

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0 \quad \checkmark$$

$$\alpha = 0.05$$

$$pV = 0.0132 < \alpha$$

Se rechaza H_0

↑
equiválentes
↓

$$H_0: \mu_1 - \mu_2 = 0$$

$$H_1: \mu_1 - \mu_2 \neq 0$$

$$\alpha = 0.05$$

$$pV = 0.0132 < \alpha$$

Se rechaza H_0

Un factor dicotómico y una variable cuantitativa, sin interacción

Suponga ahora que se añade una variable cuantitativa X_2 :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

¿Qué sucede cuando $X_1 = 0$ y cuando $X_1 = 1$? ¿qué característica presentan las líneas de regresión estimadas?

$$\left. \begin{array}{l} X_1 = 1 : Y = (\beta_0 + \beta_1) + \beta_2 X_2 + \epsilon \\ X_1 = 0 : Y = \beta_0 + \beta_2 X_2 + \epsilon \end{array} \right\} \begin{array}{l} \text{diferente intercepto} \\ \text{misma pendiente} \rightarrow \text{paralelas} \end{array}$$

```
modelo2 = lm(Nota~Turno+PC1,datosA)
modelo2 |> summary()
```

```
Call:
lm(formula = Nota ~ Turno + PC1, data = datosA)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-6.5593 -2.0885  0.3823  2.1560  4.6925
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   4.3948     4.6158   0.952  0.3505
TurnoNoche    -0.5620     1.8083  -0.311  0.7586
PC1           0.7482     0.2907   2.574  0.0167 *
```

$$\hat{y} = 4.39 - 0.56\text{Turno} + 0.75\text{PC1}$$

$\text{Noche} = 1 \rightarrow \text{Mañana} = 0$
 $\text{Mañana} = 1 \rightarrow \text{Noche} = 0$

* Turno mañana : $\hat{y} = 4.39 + 0.75\text{PC1}$

* Turno noche : $\hat{y} = 3.83 + 0.75\text{PC1}$

✗ Nota ~ Turno	→	R^2	22.16%	R^2_j	19.04%	$\hat{Y} = 16.0667 - 3.8167 \times Turno$
Nota ~ PC1	→		38.45%	36.3%		$\hat{Y} = 3.2817 + 0.8114 \times PC1$
Nota ~ Turno + PC1	→		39%	33.91%		$\hat{Y} = 4.3948 - 0.562 \times Turno + 0.7482 \times PC1$

$\hat{Y} = 16.0667 - 3.8167 \times Turno$

(Annotations: "PTOS" above the equation; "Mañana = 0" and "Noche = 1" with arrows pointing to the Turno variable)

- -3.8167: los estudiantes del turno noche (1) tienen en promedio 3.8167 puntos menos en la nota que los del turno mañana (0)

$\hat{Y} = 3.2817 + 0.8114 \times PC1$

(Annotations: "PTOS nota" above the equation; "PTOS de PC1" above the PC1 variable; "puntos de nota / pto PC1" below the coefficient 0.8114)

- 0.8114: por cada punto adicional que un estudiante obtiene en la PC1, se espera que su nota final aumente, en promedio, 0.8114 puntos

$\hat{Y} = 4.3948 - 0.562 \times Turno + 0.7482 \times PC1$

- -0.562: los estudiantes del turno noche (1) tienen en promedio 0.562 puntos menos en la nota que los del turno mañana (0), manteniendo fija la nota de la PC1.

- 0.7482: por cada punto adicional que un estudiante obtiene en la PC1, se espera que su nota final aumente, en promedio, 0.7482 puntos, manteniendo el turno constante.

e,

Un factor dicotómico y una variable cuantitativa, con interacción

Suponga ahora que la variable cuantitativa X_2 interactúa con el factor dicotómico. El modelo quedaría expresado como:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_{1,2} + \epsilon$$

Handwritten red annotations:
- A red arrow points from the word "cuale" to X_1 .
- A red arrow points from the word "cuanti" to X_2 .
- A red bracket under $X_{1,2}$ is labeled with $X_1 \times X_2$.

¿Cuáles serían las unidades de los coeficientes de regresión estimados? ¿Cómo se interpretarían?

	\times	$\text{Nota} \sim \text{Turno}$	\longrightarrow	R^2					
		$\text{Nota} \sim \text{PC1}$	\longrightarrow	22.16%		R^2_{aj}			$\hat{Y} = 16.0667 - 3.8167 \times \text{Turno}$
				38.75%		19.04%			$\hat{Y} = 3.2817 + 0.8114 \times \text{PC1}$
\longrightarrow	\bullet	$\text{Nota} \sim \text{Turno} + \text{PC1}$	\longrightarrow	39%	\uparrow	36.3%			$\hat{Y} = 4.3948 - 0.562 \times \text{Turno} + 0.7482 \times \text{PC1}$
\longrightarrow	\bullet	$\text{Nota} \sim \text{Turno} + \text{PC1}$	\longrightarrow	39%		33.91%			
		\downarrow				31.05%			
		$\text{Turno} + \text{PC1} + \text{Turno} \times \text{PC1}$							

```
modelo4 = lm(Nota~Turno*PC1,datosA)
modelo4 |> summary()
```

Call:

```
lm(formula = Nota ~ Turno * PC1, data = datosA)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-6.5721	-2.0537	0.3671	2.1477	4.6724

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.78829	9.81540	0.488	0.630
TurnoNoche	-1.03768	10.56875	-0.098	0.923
PC1	0.72297	0.62666	1.154	0.260
TurnoNoche:PC1	0.03253	0.71160	0.046	0.964

Residual standard error: 3.409 on 23 degrees of freedom

Multiple R-squared: 0.39, Adjusted R-squared: 0.3105

F-statistic: 4.902 on 3 and 23 DF, p-value: 0.008877

$$\hat{y} = 4.79 - 1.04 \text{ Turno} + 0.72 \text{ PC1} + 0.03 \text{ Turno} \times \text{PC1}$$

$N=0$
 $N=1$

Turno mañana

$$\hat{y} = 4.79 + 0.72 \text{ PC1}$$

Turno Noche

$$\hat{y} = (4.79 - 1.04) + 0.72 \text{ PC1} + 0.03 \text{ PC1}$$

$$\hat{y} = 3.75 + 0.75 \text{ PC1}$$

→ modelo simple

→ modelo completo

```
modelo2 |> anova(modelo4)
```

Analysis of Variance Table

Model 1: Nota ~ Turno + PC1

Model 2: Nota ~ Turno * PC1

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	24	267.37				
2	23	267.35	1	0.024288	0.0021	0.9639

modelo2: $Y = \beta_0 + \beta_1 \text{Turno} + \beta_2 \text{PC1} + \epsilon$ ✓

modelo4: $Y = \beta_0 + \beta_1 \text{Turno} + \beta_2 \text{PC1} + \beta_3 \text{TurnoPC1} + \epsilon$

$H_0: \beta_3 = 0 \rightarrow$ elegir modelo 2 ✓

$H_1: \beta_3 \neq 0 \rightarrow$ elegir modelo 4

$\alpha = 0.05$

$pV = 0.96$

Decision: No se rechaza H_0

```
modelo1 |> anova(modelo2)
```

Analysis of Variance Table

Model 1: Nota ~ Turno \longrightarrow modelo 1: $\gamma = \beta_0 + \beta_1 \text{Turno} + \varepsilon$

Model 2: Nota ~ Turno + PC1 \longrightarrow modelo 2: $\gamma = \beta_0 + \beta_1 \text{Turno} + \beta_2 \text{PC1} + \varepsilon$

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	25	341.18				
2	24	267.37	1	73.81	6.6253	0.01665 *

$H_0: \beta_2 = 0 \rightarrow$ elegir modelo 1 \times

$H_1: \beta_2 \neq 0 \rightarrow$ elegir modelo 2 \checkmark

$\alpha = 0.05$

$pV = 0.01665$

Decisión: Rechazar H_0

```
modelo3 |> anova(modelo2)
```

Analysis of Variance Table

Model 1: Nota ~ PC1 → modelo 3: $Y = \beta_0 + \beta_2 PC1 + E$ ✓
Model 2: Nota ~ Turno + PC1 → modelo 2: $Y = \beta_0 + \beta_1 Turno + \beta_2 PC1 + E$
Res.Df RSS Df Sum of Sq F Pr(>F)
1 25 268.45
2 24 267.37 1 1.0761 0.0966 0.7586

$H_0: \beta_1 = 0 \rightarrow$ elegir modelo 3 ✓
 $H_1: \beta_1 \neq 0 \rightarrow$ elegir modelo 2
 $\alpha = 0.05$
 $pV = 0.76$
Decision: no rechazar H_0

$$\text{Modelo 3: } \hat{Y} = 3.2817 + 0.8114 \times PC1$$